数据分析—2016 棒球赛季数据分析

提出问题

1. 指标打数(AB)是否和得分数(R)正相关
2. 指标安打数(H)是否和得分数(R)正相关
3. 指标本垒打数(HR)是否和得分数(R)正相关

这里，打数、安打数、本垒打数是三个自变量，得分数是因变量

数据加工

导入包

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
%matplotlib inline
```

载入数据

```
batting_df = pd.read_csv('Batting.csv')
```

熟悉数据

先看看数据里都有哪些信息，这些信息是怎样的格式。

Batting.csv：

- playerID => 球员 id
- yearID => 年份
- teamID => 所在球队
- lgID => 所属联盟
- G => 参加比赛数量
- AB => 打数
- R => 得分
- H => 安打
- 2B => 二垒安打
- 3B => 三垒安打
- HR => 全垒打
- RBI => 打点
- SB => 盗垒
- CS => 偷垒被杀
- BB => 四坏球后送上垒
- SO => 三振出局
- IBB => 被故意四坏保送次数
- HBP => 触身球
- SH => 牺牲打
- SF => 牺牲高飞球长打

- GIDP => 双杀打

```
batting_df.head()
```

	playerID	yearID	stint	teamID	lgID	G	AB	R	H	2B	...	RBI	SB	CS	BB	SO	IBB	HBP	SH	SF	GIDP
0	abercda01	1871	1	TRO	NaN	1	4	0	0	0	...	0.0	0.0	0.0	0	0.0	NaN	NaN	NaN	NaN	NaN
1	addybo01	1871	1	RC1	NaN	25	118	30	32	6	...	13.0	8.0	1.0	4	0.0	NaN	NaN	NaN	NaN	NaN
2	allisar01	1871	1	CL1	NaN	29	137	28	40	4	...	19.0	3.0	1.0	2	5.0	NaN	NaN	NaN	NaN	NaN
3	allisdo01	1871	1	WS3	NaN	27	133	28	44	10	...	27.0	1.0	1.0	0	2.0	NaN	NaN	NaN	NaN	NaN
4	ansonca01	1871	1	RC1	NaN	25	120	29	39	11	...	16.0	6.0	2.0	2	1.0	NaN	NaN	NaN	NaN	NaN

数据清洗

```
#仅保留某一年的数据
def keep_data_in_year(df, year):
    return df[df.yearID == year]

batting_df_2016 = keep_data_in_year(batting_df, 2016)
batting_df_2016.head()
```

	playerID	yearID	stint	teamID	lgID	G	AB	R	H	2B	...	RBI	SB	CS	BB	SO	IBB	HBP	SH	SF	GIDP
101333	abadfe01	2016	1	MIN	AL	39	1	0	0	0	...	0.0	0.0	0.0	0	1.0	0.0	0.0	0.0	0.0	0.0
101334	abadfe01	2016	2	BOS	AL	18	0	0	0	0	...	0.0	0.0	0.0	0	0.0	0.0	0.0	0.0	0.0	0.0
101335	abreujo02	2016	1	CHA	AL	159	624	67	183	32	...	100.0	0.0	2.0	47	125.0	7.0	15.0	0.0	9.0	21.0
101336	achteaj01	2016	1	LAA	AL	27	0	0	0	0	...	0.0	0.0	0.0	0	0.0	0.0	0.0	0.0	0.0	0.0
101337	ackledu01	2016	1	NYA	AL	28	61	6	9	0	...	4.0	0.0	0.0	8	9.0	0.0	0.0	0.0	1.0	0.0

5 rows × 22 columns

```
# 查看看哪些字段存在数据缺失的情况
batting_df_2016.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1483 entries, 101333 to 102815
Data columns (total 22 columns):
playerID    1483 non-null object
yearID      1483 non-null int64
stint       1483 non-null int64
teamID      1483 non-null object
lgID        1483 non-null object
G           1483 non-null int64
AB          1483 non-null int64
R           1483 non-null int64
H           1483 non-null int64
2B          1483 non-null int64
3B          1483 non-null int64
HR          1483 non-null int64
RBI         1483 non-null float64
SB          1483 non-null float64
CS          1483 non-null float64
BB          1483 non-null int64
SO          1483 non-null float64
IBB         1483 non-null float64
HBP         1483 non-null float64
SH          1483 non-null float64
SF          1483 non-null float64
GIDP        1483 non-null float64
```

```
dtypes: float64(9), int64(10), object(3)
memory usage: 266.5+ KB
```

从上面的信息中可以看到，各字段信息保持完整。

数据探索

```
#定义公用函数

#绘制直方图
def draw_his(df, key_name, x_label, title):
    plt.hist(df[key_name], bins=6)
    plt.xlabel(x_label)
    plt.ylabel('Frequency')
    plt.title(title)

#绘制散点图
def draw_scatter(df, x_axis_key, y_axis_key, title):
    plt.scatter(x = df[x_axis_key], y = df[y_axis_key])
    plt.xlabel(x_axis_key)
    plt.ylabel(y_axis_key)
    plt.title(title)
```

打数(AB)和得分数(R)的关系

```
#打点数AB统计数据
batting_df_2016['AB'].describe()
```

```
count    1483.000000
mean      111.639245
std       177.929105
min         0.000000
25%         0.000000
50%        11.000000
75%       155.000000
max       672.000000
Name: AB, dtype: float64
```

```
#得分R统计数据
batting_df_2016['R'].describe()
```

```
count    1483.000000
mean       14.662171
std        25.802684
min         0.000000
25%         0.000000
50%         1.000000
75%        18.000000
max       123.000000
Name: R, dtype: float64
```

```
#绘制打点数AB的直方图
draw_his(batting_df_2016, 'AB', 'AB', 'AB in 2016')
```

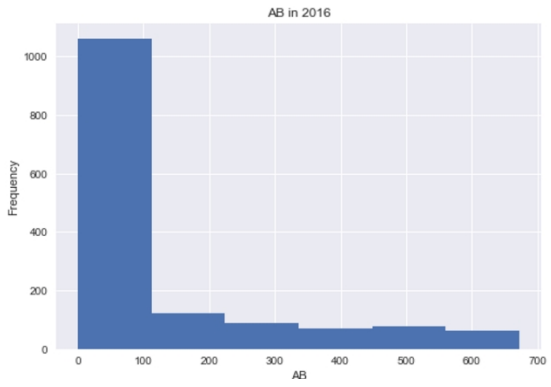

```
#绘制打点数AB的直方图
draw_his(batting_df_2016, 'R', 'R in 2016')
```

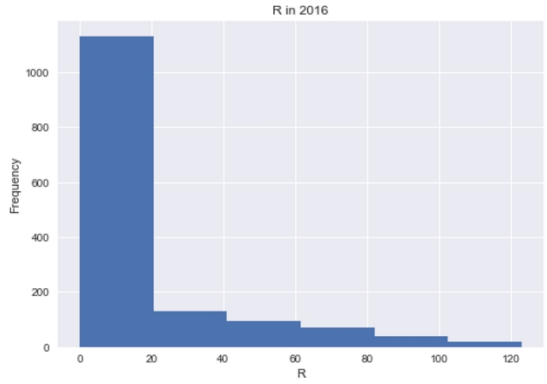


```
#绘制打点数AB和得分数的散点图
draw_scatter(batting_df_2016, 'AB', 'R', 'AB & R in 2016')
```

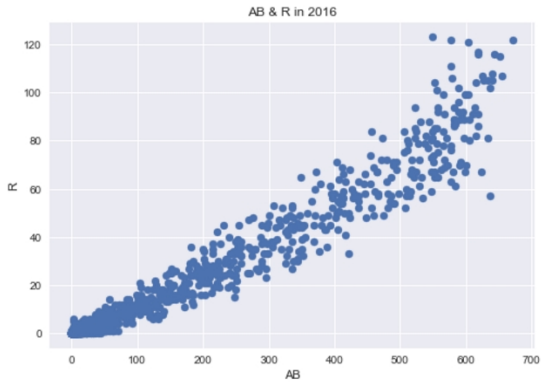


```
#计算皮尔逊系数R
np.corrcoef(batting_df_2016['AB'], batting_df_2016['R'])[1, 0]
```

```
0.97566869148528623
```

可以看出得分 R 和打点数 AB 都集中在 0 附近，直方图成正偏态分布

散点图表明 R 和 AB 成正相关，皮尔逊系数 r = 0.976 表明两者有非常强的正相关

安打数(H)和得分数(R)的关系

```
#安打数H统计数据
batting_df_2016['H'].describe()
```

```
count    1483.000000
mean       28.507080
std        48.619753
min         0.000000
25%         0.000000
50%         1.000000
75%        36.000000
max       216.000000
Name: H, dtype: float64
```

```
#绘制安打数H的直方图
draw_his(batting_df_2016, 'H', 'H', 'H in 2016')
```

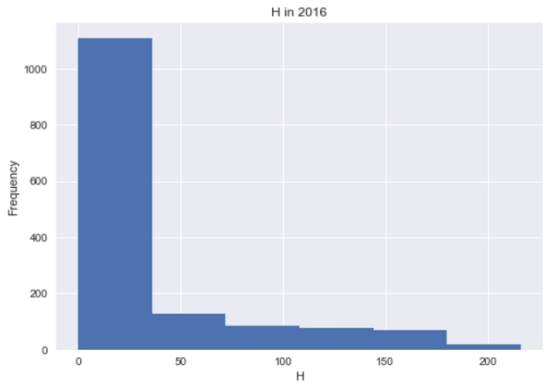


```
#绘制打点数AB和得分数的散点图
draw_scatter(batting_df_2016, 'H', 'R', 'H & R in 2016')
```

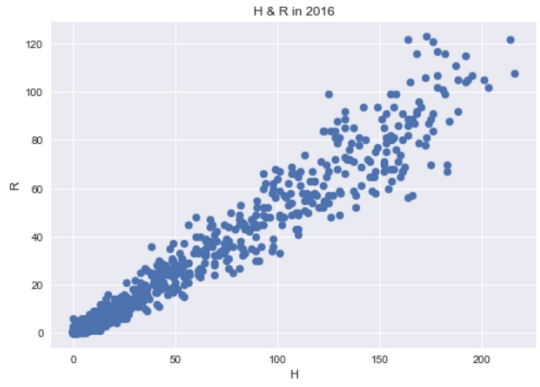


```
#计算皮尔逊系数R
np.corrcoef(batting_df_2016['H'], batting_df_2016['R'])[1, 0]
```

```
0.98009961650128763
```

可以看出得分 R 和安打数 H 都集中在 0 附近，直方图成正偏态分布

散点图表明 R 和 H 成正相关，皮尔逊系数 r = 0.98 表明两者有非常强的正相关

本垒打数(HR)和得分数(R)的关系

```
#本垒打数HR统计数据
batting_df_2016['HR'].describe()
```

```
count    1483.000000
mean        3.782873
std         7.863979
min         0.000000
25%         0.000000
50%         0.000000
75%         3.000000
max        47.000000
Name: HR, dtype: float64
```

```
#绘制本垒打数HR的直方图
draw_his(batting_df_2016, 'HR', 'HR', 'HR in 2016')
```

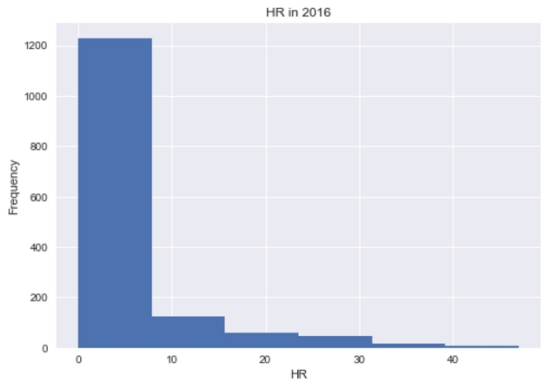


```
#绘制本垒打数HR和得分数R的散点图
draw_scatter(batting_df_2016, 'HR', 'R', 'HR & R in 2016')
```

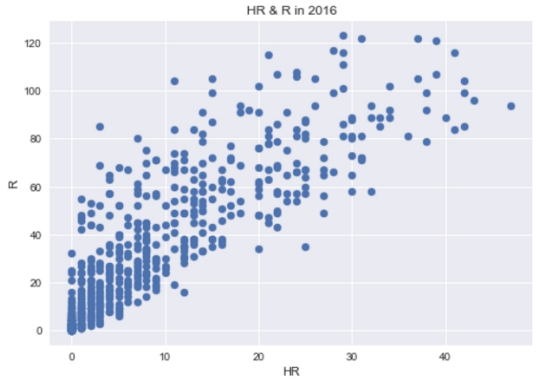


```
#计算皮尔逊系数R
np.corrcoef(batting_df_2016['HR'], batting_df_2016['R'])[1, 0]
```

```
0.90078317451199441
```

可以看出得分 R 和本垒打数 HR 都集中在 0 附近，直方图成正偏态分布
散点图表明 R 和 HR 成正相关，皮尔逊系数 r = 0.9 表明两者有非常强的正相关

结论

通过以上分析，可以看出打数、安打数、本垒打数和得分数有很强的正相关性，其中打数和安打数相关性最强非常接近 1，本垒打数稍低。

分析的局限性

这里并没有从统计上分析得出这些结果的偶然性，所以并不知道这里的结果是真正的差异造成的还是噪音造成的。

结果的相关性

这里的数据并非是通过试验得出，所以无法说自变量和因变量之间有因果性，只能说它们之间有相关性。